Regularni izrazi

1 Osnovni regularni izrazi

Regularni izrazi predstavljaju mehanizam za prepoznavanje određenih šablona u tekstu. Osnovni regularni izrazi su:

- a: Ako je a karakter iz azbuke, tada je a regularni izraz koji prepoznaje samo taj karakter.
- $r_1 r_2$: Ako su r_1 i r_2 regularni izrazi, tada je $r_1 r_2$ regularni izraz koji prepoznaje niz gde se r_2 nalazi nakon r_1.
- r_1 | r_2: Ako su r_1 i r_2 regularni izrazi, tada je $r_1 | r_2$ regularni izraz koji prepoznaje sve što prepoznaje r_1 ili r_2.
- $r*$: Za regularni izraz r, izraz $r*$ prepoznaje 0 ili više pojavljivanja izraza r.

2 Prošireni regularni izrazi

Radi skraćivanja zapisa regularnog izraza i povećanja čitljivosti, uvode se tzv. *prošireni regularni izrazi* koji predstavljaju kraće zapise nekih osnovnih regularnih izraza.

Prošireni regularni izraz	**Opis**
`[`$a_1 a_2 \ldots a_n$`]`	`a_1 | a_2 | ... | a_n`
`[^`$a_1 a_2 \ldots a_n$`]`	Svi karakteri iz azbuke bez $\{a_1, a_2, \ldots, a_n\}$
`[a_1 - a_2]`	Disjunkcija karaktera od a_1 do a_2 iz ASCII tabele
`\w`	`[A-Za-z0-9_]`
`\W`	`[^A-Za-z0-9_]`
`\d`	`[0-9]`
`\D`	`[^0-9]`
`\s`	`[ \t\r\n\f]` (sve bjeline)
`\S`	`[^ \t\r\n\f]`
`.`	`[^\n]` (sve osim novog reda)
`a+`	aa^* (jedno ili više pojavljivanja)
`a?`	$\varepsilon \mid a$ (nula ili jedno pojavljivanje)
`a{n}`	a^n
`a{n,m}`	$a^k,\ n \leq k \leq m$
`a{n,}`	$a^k,\ n \leq k$

Karakteri sa specijalnim značenjem **u karakterskoj klasi**:

`-, \, ], ^`

Karakteri sa specijalnim značenjem **van karakterske klase**:

`*, +, ?, |, ., \, (, ), [, ...`

Za oduzimanje specijalnog značenja koristi se `\` (*backslash*).

3 Gramzivost i lenjo izračunavanje

Gramzivost: Poklapanje izraza vrši se u poslednjem mogućem trenutku. Gramzivi operatori su: `*, +, ?, { }`

Gramzivost se uklanja dodatnim operatorom `?` ukoliko je to podržano. Na primer: `a+?` je negramzivo poklapanje.

Lenjo izračunavanje: Ako se u alternaciji prepozna prvi operand, drugi se ne razmatra.

4 Sidra

Sidra određuju položaj prepoznavanja regularnog izraza u tekstu, ne prepoznaju karaktere.

- `^` — početak teksta ili linije (u `multiline` režimu)
- `$` — kraj teksta ili linije (u `multiline` režimu)
- `\b` — granica reči

5 Preduvidi i postuvidi

5.1 Pozitivni preduvid

$r_1\,(?=r_2)$	regularni izraz r_1 nakon kojeg se nalazi r_2
$(?=r_1)\,r_2$	regularni izraz r_2 koji počinje regularnim izrazom r_1

5.2 Negativni preduvid

$r_1\,(?!r_2)$	regularni izraz r_1 nakon kojeg se *ne* nalazi regularni izraz r_2
$(?!r_1)\,r_2$	regularni izraz r_2 koji *ne* počinje regularnim izrazom r_1

5.3 Pozitivni postuvid

$(? <= r_1)\, r_2$	regularni izraz r_2 ispred kojeg se nalazi regularni izraz r_1
$r_1\, (? <= r_2)$	regularni izraz r_1 koji se završava regularnim izrazom r_2

5.4 Negativni postuvid

$(? <! r_1)\, r_2$	regularni izraz r_2 ispred kojeg se *ne* nalazi regularni izraz r_1
$r_1\, (? <! r_2)$	regularni izraz r_1 koji se *ne* završava regularnim izrazom r_2

6 Grupisanje i referenciranje (Backreferences)

Grupisanje se vrši stavljanjem dela izraza u zagrade (). Grupama se pristupa pomoću reference `\k`, gde je k redni broj grupe. Numeracija odgovara redosledu otvorenih zagrada.